

高质量数据集建设——必知要点

****一句话版本**：高质量数据集 = 能直接喂给 AI**

模型、并且确实能让模型变聪明的数据。《高质量数据集建设指引》是国家数据局指导 6 家机构编制的官方方法论，告诉你如何系统地建**、**评**、**用**这种数据。**

文中标 `[引用N]`

的政策/数据均可查证，出处与链接见文末 [参考资料](#参考资料)。

1. 为什么现在必须关注



大模型时代，研发重点已从"优化模型架构"转向"模型与数据协同优化"**——数据质量直接决定模型上限。**

- 政策节奏记 3 个节点即可：

-

****2022.12** 《关于构建数据基础制度更好发挥数据要素作用的意见》`[引用1]`**

-

****2024.12** 《关于促进数据产业高质量发展的指导意见》首次明确"高质量数据集"概念`[引用2]`**

- ****2025.02** 国家数据局组织 27**

个部委召开高质量数据集建设工作启动会，进入系统化、规模化推进阶段`[引用3]`

-

结论：这是国家层面确定要干的事，标准、项目、岗位会陆续跟上，现在懂正是时候**。**

2. 什么是高质量数据集（3 分钟搞懂）

****定义**：经过采集、加工等处理，可直接用于**

开发和训练 AI

模型，能有效提升模型表现的数据集合。

****记四个要素****（以"教模型识别猫"为例）：

| 要素 | 是什么 | 例子 |

| --- | --- | --- |

| ****样本**** | 数据的基本单元 | 一张猫的照片 |

| ****特征**** | 模型看的输入属性 |

照片的像素、轮廓、纹理 |

| ****标签**** | 正确答案 | "这是猫" |

| ****元数据**** | 数据的数据 |

拍摄时间、地点、相机型号 |

****高质量 =**

规模"大"、安全"牢"、观点"正"、效果"好"、应用"广"。****（五维标准）**

补充：质量要****静态 +**

动态双轨评价——静态看数据本身（准确、完**

整、一致、合规），动态跑模型实测效果（是否真让模型变强）。

3.

数据飞轮（最重要的机制，先记住它）

****好数据 → 好模型 → 更好数据 → 更好模型.....** 的正向循环。**

落地四步（缺一不可）：

1.

****数据当活资产**：不是收集完就束之高阁，而
要持续投资、管理、监控、优化；**

2.

****流程自动化**：用可编程、可扩展的处理流程
取代一次性手工处理；**

3.

****专家进流水线**：让领域专家参与定义标准、
标注复杂案例、识别细微偏差；**

4.

****模型反馈闭环****：把模型在实际应用中的****错误当作诊断信号****（标签错了？数据分布不均？边界案例缺失？）→ 针对性改进数据集。

****一句话****：数据集不是“做一次就完”的工程项目，而是****越转越快、越用越值钱****的资产。这就是为什么第 10 节专门讲“以用促建”。

4. 最核心框架：数据分三层（必须记住）

AI 能力分三档，每档需要的数据完全不同：

层次	回答的问题	要什么数据	典型例子
----	-------	-------	------

---	---	---	---
-----	-----	-----	-----

基础认知层	这是什么	海量（TB~PB	
------------------	------	----------	--

级）、无需精细标注	GPT		
-----------	-----	--	--

预训练读全网网页、书籍			
-------------	--	--	--

场景理解层	这里发生了什么		
------------------	---------	--	--

十万~百万条精细标注			
------------	--	--	--

自动驾驶标注"红灯、行人、车距" |

| **行动规划层 | 怎么做 | 完整推理过程 +**

****价值对齐** | 让 AI**

一步步解数学题、帮你订行程 |

****两个隐藏知识点**：**

- ****尺度定律 (Scaling**

Law) **：基础认知层为什么需要海量数据？因为模型性能随数据规模呈幂律提升——数据越多，学到稳定可靠模式的能力越强。

-

****价值对齐**：**行动规划层最贵也最不能省的要求——AI

的决策要符合人类价值观、道德准则，通常靠

****RLHF (人类反馈强化学习) ****

迭代，并配伦理审查。

****类比**：**像培养一个"数字员工"——

- **基础层 = 通识教育 (上知天文下知地理)**

- 理解层 = 专业培训（看得懂场景和关系）
- 行动层 =
上岗办事（会推理、会决策、守规矩）

一层压一层，**不能跳级**。地基（基础认知）不牢，后面都白搭。

5. 再认两个分类维度（防止概念混淆）

除了按认知层次分，数据集还有两种常用分法：

| 维度 | 分类 | 一句话 |

|---|---|---|

| **模型阶段** | 预训练 / 微调 / 评估 |

通识教育 / 专业精修 / 考试卷 |

| **行业应用** | 通识 / 行业通识 / 行业专识 |

人人都懂（百度百科） / 从业者懂（行业报告） /
专家才懂（电子病历） |

****理解****：同一个数据集，用在哪一步、服务谁，决定了它该长什么样。

6. 两种建设模式：先选对方向

| 模式 | 怎么建 | 什么时候用 | 例子 |

| --- | --- | --- | --- |

| ****场景驱动**** |

先有业务场景，倒推需要什么数据 |

****大部分情况（推荐）**** | 医院要肺结节筛查 →
收集 1 万例 CT + 医生勾画病灶边界 |

| ****数据驱动**** | 先攒海量数据，再挖价值 |

通用大模型 / 预训练 |

把全网文本打包喂给大模型 |

****口诀****：要解决具体问题 →

场景驱动；要炼通用模型 → 数据驱动。

7. 建设六环节：一个流程闭环

...

数据需求 → 数据规划 → 数据采集 →
数据预处理 → 数据标注 → 模型验证

↑

——|（不达标就回炉）

...

****类比做菜**：定菜谱 → 买菜 → 洗切 → 调味
→ 试吃，不好吃就回锅重来。**

关键点："模型验证"是闸门**。效果不达标时
，按**四步归因法**处理：**

- 1. 判断是**数据问题还是算法问题**（根本原因在哪）；**
 - 2. 是数据问题 → 反馈给上游环节；**
 - 3. 迭代重做规划/采集/预处理/标注；**
 - 4. 重建模型再验证。**
- 而不是盲目堆数据。**

8. Human-in-the-Loop: 人始终在"环"里

原文和 Skill

都没出现"人在回路"这四个字，但**人的角色贯穿全书**——专家不是旁观者，而是被写进流水线的一环。散落各处的"人"，其实是同一件事。

| 原文出处 | 原话要点 | 人的角色 |

| --- | --- | --- |

| 数据飞轮（原文 p.1） |

"将拥有深厚行业知识的主题专家直接整合到数据处理的流水线中"，用专家知识"定义数据标准、标注复杂案例、识别数据中的细微偏差" |

专家是流水线的内嵌件 |

| 行动规划层（原文 p.14） |

推理的"每个推导步骤都能被人类专家理解和审核"；价值对齐靠 RLHF 迭代 +

领域专家多轮评估 +

**伦理审查；构建靠"跨学科团队：领域专家提供
专业知识、标注员精细标注、算法工程师设计验证机制" | RLHF = 人类反馈进环；跨学科团队
= 人在环的组织形态 |**

| 六环节·标注（原文 p.28） |

**标注环节要"对数据标注过程进行监督和质量管
理" | 人监督标注质量 |**

| 数据标注技术（原文 p.32） |

**标注正"从传统人工标注向智能化、自动化标注
转变"；半自动化标注 = AI 辅助工具 +
人工复核（阿里平台：自动预标注 +
人工复核） | 机器预标，人做裁判 |**

| 质量评价（原文 p.38） |

自动化检测工具快速筛查 +

"组织专家评审从专业角度把关" +

收集用户反馈 | 自动初筛，专家终审 |

| 运营维护 (原文 p.43) |

"自动化扫描与人工复核等手段处理异常" |

自动扫描, 人工复核异常 |

****一句话****: 机器负责"量大管饱", 人负责"把关纠偏"——HITL

不是某一个环节, 而是贯穿全生命周期的一条线:

****专家定标准 → 人工/半自动标注 → 自动扫描 + 人工复核 → 专家评审 → RLHF 反馈迭代****

****为什么值得单独记****: 以后评估供应商或标注基地时, "人在回路"是判断数据质量的第一提问——对方说"全自动标注", 立刻追问: 复核机制在哪? 专家参与度多高? 数据飞轮里专家卡在哪个环节?

9. 质量怎么评: 看三个维度

| 维度 | 看什么 | 一句话 |

|---|---|---|

| ****说明文档**** |

数据"说明书"全不全（规模、格式、来源、标注规则） | 文档清楚 |

| ****数据质量**** |

数据本身干不干净（规范、真实、一致、无脏数据） | 数据干净 |

| ****模型应用**** |

能不能真把模型变好（多样、时效、标注准、适配） | 模型有用 |

****口诀：文档清楚、数据干净、模型有用。 ****

两个原则：

●

****以评促建、以评促用****：评价不是"打分交差"，而是倒逼数据生产提质增效的杠杆；

●

不同行业侧重不同：****医疗重合规安全，工业重**

真实多样**。

10. 建成之后：运营反哺建设（以用促建）

数据建成上线只是开始，运营阶段有四大目标：

| 目标 | 怎么做到 | 例子 |

| --- | --- | --- |

| **需求响应及时** |

跨场景复用，打破"一数据集一模型" |

通识文本既能预训练，也能做情感分析 |

| **成本精准可控** | 核算 → 优化 →

内部/外部结算 |

内部按调用量分摊，外部按质量/稀缺度定价 |

| **质量安全可信** | 全生命周期监控 +

合规（去标识化、版本控制） |

敏感医疗数据脱敏后再开放 |

| **生态价值共创** | 分级共享 +

按贡献度分配收益 |

基础数据开源，专有数据走可信数据空间 |

****核心思想**：数据在**使用中**才会暴露问题、产生价值——运营反过来指导下一次建设，这就是数据飞轮的落地版。**

11. 避坑清单（最容易犯的 5 个错）

1. **数据用完就扔 → 数据飞轮转不起来。**

2. **只堆数量 →**

重复、脏、偏的数据堆再多也白搭，要"量质并重"。

3. **跳层建设 →**

地基（基础认知）没打好就想做决策层。

4. **建完不验证 →**

不知道数据到底有没有用，反馈闭环断了。

5. **一个数据集只服务一个模型 →**

浪费，要跨场景复用。

12. 现状数字（聊天、开会直接用）

- 全国（截至 2025.06）：****3.5 万+ 高质量数据集****、总量 ****400PB+****；挂牌交易 3364 个、累计交易额近 ****40 亿元**** `[引用3]`
- 国内多数模型****中文数据占比 60%~80%**** `[引用3]`
- 七大标注基地：成都 / 沈阳 / 合肥 / 长沙 / 海口 / 保定 / 大同 `[引用3]`
- 主要挑战就五个字：****供给、技术、标准、安全、模式****（数据供给结构性短缺、工具链薄弱、标准待完善、安全合规难平衡、商业闭环未形成） `[引用3]`

参考资料

核实日期：2026-08-06。以下为官方可查证来源；未核实到官方公开链接的条目已如实标注。

1. ** 《中共中央

**国务院关于构建数据基础制度更好发挥数据要素
作用的意见》** (2022-12-19
发布，第八条含"探索开展数据质量标准化体系
建设")**



**中国政府网： [https://www.gov.cn/zhengce/
2022-12/19/content_5732695.htm](https://www.gov.cn/zhengce/2022-12/19/content_5732695.htm)**

2.

**** 《"数据要素×"三年行动计划（2024—2026
年）》** (2023-12-31，国家数据局等 17
部门印发，国数政策〔2023〕11 号)**



**中国政府网（部门信息）： [https://www.gov.
cn/lianbo/bumen/202401/content_69243
80.htm](https://www.gov.cn/lianbo/bumen/202401/content_6924380.htm)**



国家数据局官网：https://www.nda.gov.cn/sjj/xxgk/gknr/ghjh/0909/20240909160155798592998_pc.html

3.

**** 《关于促进数据产业高质量发展的指导意见》**

**** (2024-12, 国家发展改革委、国家数据局、教育部、财政部、金融监管总局等联合印发)**

●

中国政府网：https://www.gov.cn/zhengce/zhengceku/202412/content_6995430.htm

●

国家发展改革委：https://www.ndrc.gov.cn/xxgk/zcfb/tz/202412/t20241230_1395341.html

●

国家发展改革委解读：https://www.ndrc.gov.cn/xxgk/jd/jd/202412/t20241230_13953

45.html

4. ****2025.02 国家数据局组织 27**

个部委召开高质量数据集建设工作启动会**

——
**信息源自《高质量数据集建设指引》正文；本次
核查在 gov.cn**

**公开检索中未找到独立官方报道，建议以国家数
据局官网发布为准：<https://www.nda.gov.cn>
/**

5. ****我国建设现状数据（截至
2025.06）与七大标注基地** ——**

均源自《高质量数据集建设指引》第三章

6.
****配套技术文件（征求意见稿）**：《高质量数
据集 分类指南》《高质量数据集
建设指南》《高质量数据集
质量评测规范》——**

书中引用名称，具体以全国数据标准化技术委员会 / 国家数据局正式发布为准

想深入？去哪看

- **全书框架速览** → ``SKILL.md`` (或 ``chapters/`` 各章)
- **术语查询** → ``glossary.md``
- **决策速查 + 反模式** → ``cheatsheet.md``
- **原文全文** → ``source/高质量数据集建设指引.pdf``